

Rapport de Projet

Medical Agentic AI System basé sur RAG

Mohamed Aziz El Hamrouni

16 mai 2026

Résumé

Ce projet propose un système médical intelligent basé sur le Retrieval-Augmented Generation (RAG), des agents intelligents et des APIs externes afin de réduire les hallucinations des modèles de langage et améliorer la fiabilité des réponses dans le domaine médical.

Table des matières

1	Introduction	1
2	Objectif du projet	2
3	Description du système	3
3.1	Vue générale	3
3.2	Fonctionnement global	3
4	Architecture du système	4
4.1	Architecture en couches	4
4.1.1	Interface utilisateur	4
4.1.2	Couche Agent	4
4.1.3	Couche RAG	4
4.1.4	Couche APIs externes	4
5	Pipeline RAG	6
5.1	Définition	6
5.2	Étapes	6
5.2.1	Ingestion des données	6
5.2.2	Vectorisation	6
5.2.3	Stockage	6
5.2.4	Retrieval	6
5.2.5	Génération	6
6	Implémentation	8
6.1	Technologies utilisées	8
6.2	Structure du projet	8
6.3	Logique de l'agent	8
7	Résultats et tests	9
7.1	Résultats	9
7.2	Exemple	9
7.3	Limites	11
8	Conclusion	12

Chapitre 1

Introduction

Avec l'évolution rapide des modèles de langage (LLMs), les systèmes d'intelligence artificielle sont capables de générer du texte cohérent et fluide. Cependant, ces modèles présentent des limites importantes dans des domaines critiques comme la médecine. Les principales limites sont :

- Absence de vérification des sources
- Risque d'hallucinations (informations fausses)
- Connaissances statiques non mises à jour

Pour résoudre ces problèmes, une approche appelée Retrieval-Augmented Generation (RAG) a été introduite. Ce projet propose un système médical intelligent combinant :

- RAG (recherche documentaire)
- Agents intelligents
- APIs médicales externes
- LLM avancé (Groq LLAMA 3)

Chapitre 2

Objectif du projet

L'objectif principal est de concevoir un assistant médical intelligent capable de :

- Comprendre les requêtes médicales complexes
- Rechercher des informations fiables dans des documents scientifiques
- Utiliser des APIs médicales externes (PubMed, WHO, FDA)
- Générer des réponses précises et contextualisées
- Réduire les hallucinations des LLMs

Le système doit agir comme un assistant médical augmenté par connaissances externes.

Chapitre 3

Description du système

3.1 Vue générale

Le système est une architecture hybride composée de trois composants principaux :

- Moteur RAG (Recherche + Génération)
- Agent intelligent (orchestration des outils)
- APIs médicales externes

3.2 Fonctionnement global

Lorsqu'une question est posée :

1. La requête est analysée par l'agent
2. L'agent décide de la stratégie (RAG/API/hybride)
3. Le système récupère les données pertinentes
4. Le LLM génère une réponse finale enrichie

Chapitre 4

Architecture du système

4.1 Architecture en couches

4.1.1 Interface utilisateur

Développée avec Streamlit :

- Interaction utilisateur
- Affichage des réponses
- Visualisation des sources

4.1.2 Couche Agent

- Analyse de la requête
- Choix des outils
- Orchestration des appels

4.1.3 Couche RAG

- Embeddings (Sentence Transformers)
- Base vectorielle FAISS
- Documents médicaux chunkés

4.1.4 Couche APIs externes

- PubMed
- WHO
- FDA
- NewsAPI




FIGURE 4.1 – Architecture détaillée du système

Chapitre 5

Pipeline RAG

5.1 Définition

Le RAG combine :

- Retrieval (recherche d'information)
- Generation (génération de texte)

5.2 Étapes

5.2.1 Ingestion des données

- Chargement de PDFs
- Nettoyage
- Chunking

5.2.2 Vectorisation

Sentence-BERT (all-MiniLM-L6-v2)

5.2.3 Stockage

FAISS vector database

5.2.4 Retrieval

- Embedding de la question
- Similarity search
- Top-k selection

5.2.5 Génération

LLM (LLaMA 3 via Groq API)

CHAPITRE 5 : SCHÉMA DU PIPELINE RAG




FIGURE 5.1 – RAG

Chapitre 6

Implémentation

6.1 Technologies utilisées

- Python 3.12
- Streamlit
- FAISS
- Sentence Transformers
- Groq API
- PubMed / WHO / FDA APIs

6.2 Structure du projet

- `app.py`
- `rag.py`
- `agent.py`
- `tools.py`

6.3 Logique de l'agent

- Question générale → RAG
- Médicament → FDA API
- Recherche scientifique → PubMed
- Sinon hybride

Chapitre 7

Résultats et tests

7.1 Résultats

- Réponses plus précises
- Réduction des hallucinations
- Meilleure traçabilité

7.2 Exemple

Question : Quels sont les effets secondaires de l'ibuprofène ?

Réponse :

- Données issues de documents médicaux
- Complément PubMed
- Validation FDA



FIGURE 7.1 – Résultat 1

Gestion des Documents

Charger un PDF médical

Drag and drop file here

Limit 200MB per file • PDF

Browse files

dermatology-handbook...

2.5MB

Document dermatology-handbook-for-medical-students-and-junior-doctors-3rd-edition-nicole-yi-zhen-chiang-julian-verbov-3814.pdf indexé.

Effacer l'historique

Deploy

Medical Agentic Research Assistant

what is Eczema from the document that i given to you

Thought: I have found information about Eczema from the document provided, but it seems to be a repetitive copy of the same text. I have also tried to summarize the information and provide a concise answer.

Action: Action Input: text="Eczema (or dermatitis) is a chronic skin condition common in children but also prevalent in adults. It has a 20% prevalence in <12 years old in the UK. The causes are not fully understood, but a positive family history of atopy and a primary genetic defect in skin barrier function are often present. Exacerbating factors include infections, allergens, sweating, heat, occupation, and severe stress."

articles about dermatology in Pubmed

The list of articles includes:

1. Tattoo Granuloma Associated With Uveitis: A Useful Temporary Entity Pending Further Clarification.
2. Keratinocyte Priming by Staphylococcus aureus Reduces HSV-1 Susceptibility.
3. The lipid-inflammation axis in rosacea: mechanistic insights and therapeutic implications.
4. Genetically Confirmed Localized Perianal Hailey-Hailey Disease Successfully Treated With Topical Difamylast: A Case Report.

Posez votre question médicale...

FIGURE 7.2 – Résultat 2

Deploy

Statistiques OMS sur la prévalence des maladies de peau dans le monde

Bien que souvent perçues comme de simples désagréments esthétiques, les affections cutanées représentent un problème de santé publique majeur. 4e cause mondiale de handicap : Selon les données partagées par l'OMS et l'étude du Global Burden of Disease (GBD), les maladies de la peau se classent au 4e rang mondial des causes d'années vécues avec une incapacité (YLD), juste derrière les pathologies sensorielles ou la tuberculose. Maladies inflammatoires en tête : Ce sont les affections non cancéreuses comme la dermatite (eczéma), l'acné, le psoriasis et l'urticaire qui génèrent la plus grande charge de morbidité tout au long de la vie. Focus sur les infections virales : Des réanalyses de données évaluent à plus de 136 millions le nombre de cas prévalents de maladies virales de la peau (herpès, molluscum, verrues), touchant particulièrement les populations jeunes (10-19 ans). Impact dans les pays en développement : Dans les régions à faibles revenus (notamment en Afrique subsaharienne et dans le Pacifique), la prévalence des maladies de peau chez les enfants peut atteindre 20 à 87 %, dominée par la gale (scabies) et les pyodermatites.

Actualités sur l'usage des biothérapies en dermatologie

Le paysage des biothérapies connaît une transformation majeure vers l'ultra-sélectivité. Ciblage de nouvelle génération : Les nouveaux anticorps monoclonaux et molécules s'éloignent de l'immunosuppression globale pour cibler des voies cytokiniques ultra-précises (comme les inhibiteurs doubles de cytokines). Cela permet de maximiser l'efficacité tout en réduisant drastiquement les effets secondaires systémiques. Médecine personnalisée : Les traitements intègrent de plus en plus le profil moléculaire et immunitaire précis du patient pour prédire la réponse thérapeutique avant même l'initiation du traitement biologique. Combinaisons innovantes : L'association de biothérapies avec des technologies physiques (comme les lasers picosecondes ou fractionnés de précision) est en plein essor pour accélérer la réparation tissulaire et potentialiser le remodelage cutané.

Données WHO sur le mélanome et les cancers cutanés

Posez votre question médicale...

FIGURE 7.3 – Résultat 3

10




FIGURE 7.4 – Résultat 4

7.3 Limites

- Latence API Groq
- Dépendance aux données
- Complexité agentique

Chapitre 8

Conclusion

Ce projet démontre l'efficacité des architectures hybrides combinant RAG, agents intelligents et LLMs dans des applications médicales.

Améliorations futures :

- Optimisation FAISS
- Mémoire conversationnelle
- Amélioration de l'agent